МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
им. Н.Э.Баумана

Отчет по рубежному контролю №1
по курсу «Технологии машинного обучения»

Технологии разведочного анализа и обработки данных.

Подготовил
Ионов С.А.
ИУ5-62Б
Вариант №10

1) Описание задания

Задача №2: для заданного набора данных проведите обработку пропусков в данных для одного категориального и одного количественного признака. Какие способы обработки пропусков в данных для категориальных и количественных признаков Вы использовали? Какие признаки Вы будете использовать для дальнейшего построения моделей машинного обучения и почему?

Дополнительно: для произвольной колонки данных построить гистограмму.

2) Текст программы

```
import pandas as pd
import numpy as np
from sklearn.impute import SimpleImputer
from sklearn.impute import MissingIndicator
import seaborn as sns
import matplotlib.pyplot as plt
from pylab import rcParams # для того, чтобы задавать размер диаграмм
%matplotlib inline

data = pd.read_csv('data/dc-wikia-data.csv', sep=',')
data.isnull().sum()
data.info()

mising_count = data.isnull().sum()
all_count = data.isnull().count()
pd.concat([mising_count.sort_values(), (mising_count/all_count*100).sort_values()],
        axis=1, keys=['Количество пропусков', 'Процент пропусков']).tail(11)

data.drop(['GSM'], axis=1, inplace=True)

rcParams['figure.figsize'] = 7,7
g = sns.kdeplot(data=data, x="APPEARANCES", shade=True)
g.set_xlabel("APPEARANCES", size = 15)
g.set_ylabel("Frequency", size = 15)
plt.title('Distribution of APPEARANCES', size = 18)

indicator = MissingIndicator()
mask_missing_values_only = indicator.fit_transform(data[['APPEARANCES']])
imp_num = SimpleImputer(strategy='most_frequent')
data_num_imp = imp_num.fit_transform(data[['APPEARANCES']])
data['APPEARANCES'] = data_num_imp
filled_data = data_num_imp[mask_missing_values_only]
print('APPEARANCES', 'most_frequent', filled_data.size, filled_data[0],
filled_data[filled_data.size-1], sep='; ')
```

3) Экранные формы с примерами выполнения программы

- В рубежном контроле использовался датасет [FiveThirtyEight Comic Characters Dataset] (файл dc-wikia-data.csv)
- Первые 5 строк набора данных имеют вид:

page_id	name	urlslug	ID	ALIGN	EYE	HAIR	SEX	GSM	ALIVE	APPEARANCES	FIRST APPEARANCE	YEAR
1422	Batman (Bruce Wayne)	\wiki\Batman_(Bruce_Wayne)	Secret Identity	Good Characters	Blue Eyes	Black Hair	Male Characters	NaN	Living Characters	3093.0	1939, May	1939.0
23387	Superman (Clark Kent)	\wiki\Superman_(Clark_Kent)	Secret Identity	Good Characters	Blue Eyes	Black Hair	Male Characters	NaN	Living Characters	2496.0	1986, October	1986.0
1458	Green Lantern (Hal Jordan)	\wiki\Green_Lantern_(Hal_Jordan)	Secret Identity	Good Characters	Brown Eyes	Brown Hair	Male Characters	NaN	Living Characters	1565.0	1959, October	1959.0
1659	James Gordon (New Earth)	\wiki\James_Gordon_(New_Earth)	Public Identity	Good Characters	Brown Eyes	White Hair	Male Characters	NaN	Living Characters	1316.0	1987, February	1987.0
1576	Richard Grayson (New Earth)	\wiki\Richard_Grayson_(New_Earth)	Secret Identity	Good Characters	Blue Eyes	Black Hair	Male Characters	NaN	Living Characters	1237.0	1940, April	1940.0

- В наборе данных присутствуют пропуски:

```
page_id              0
name                 0
urlslug              0
ID                2013
ALIGN              601
EYE               3628
HAIR              2274
SEX                125
GSM               6832
ALIVE                3
APPEARANCES        355
FIRST APPEARANCE    69
YEAR                69
dtype: int64
```

- Состав признаков в датасете:

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 6896 entries, 0 to 6895
Data columns (total 13 columns):
 #   Column            Non-Null Count  Dtype
---  ------            --------------  -----
 0   page_id           6896 non-null   int64
 1   name              6896 non-null   object
 2   urlslug           6896 non-null   object
 3   ID                4883 non-null   object
 4   ALIGN             6295 non-null   object
 5   EYE               3268 non-null   object
 6   HAIR              4622 non-null   object
 7   SEX               6771 non-null   object
 8   GSM               64 non-null     object
 9   ALIVE             6893 non-null   object
 10  APPEARANCES       6541 non-null   float64
 11  FIRST APPEARANCE  6827 non-null   object
 12  YEAR              6827 non-null   float64
dtypes: float64(2), int64(1), object(10)
memory usage: 700.5+ KB
```

- Количество и процент пропусков в данных:

	Количество пропусков	Процент пропусков
urlslug	0	0.000000
ALIVE	3	0.043503
FIRST APPEARANCE	69	1.000580
YEAR	69	1.000580
SEX	125	1.812645
APPEARANCES	355	5.147912
ALIGN	601	8.715197
ID	2013	29.190835
HAIR	2274	32.975638
EYE	3628	52.610209
GSM	6832	99.071926

- Категориальный признак «GSM» удаляем, так как он содержит большое количество пропусков (99%)
- Для числового признака «APPEARANCES» строим гистограмму распределения:

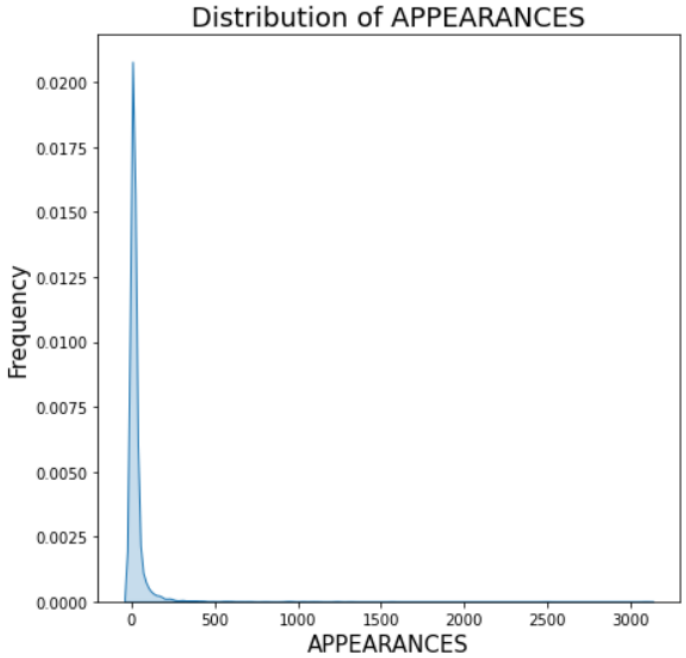

- Гистограмма имеет одномодальное распределение, поэтому для заполнения пропусков в данных используем моду:

```
APPEARANCES; most_frequent; 355; 1.0; 1.0
```

- После обработки пропусков в двух признаках имеем следующий набор данных:

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 6896 entries, 0 to 6895
Data columns (total 12 columns):
 #   Column            Non-Null Count  Dtype
---  ------            --------------  -----
 0   page_id           6896 non-null   int64
 1   name              6896 non-null   object
 2   urlslug           6896 non-null   object
 3   ID                4883 non-null   object
 4   ALIGN             6295 non-null   object
 5   EYE               3268 non-null   object
 6   HAIR              4622 non-null   object
 7   SEX               6771 non-null   object
 8   ALIVE             6893 non-null   object
 9   APPEARANCES       6896 non-null   float64
 10  FIRST APPEARANCE  6827 non-null   object
 11  YEAR              6827 non-null   float64
dtypes: float64(2), int64(1), object(9)
memory usage: 646.6+ KB
```

- Выводы, ответы на вопросы к РК:

В данной работе для обработки пропусков данных мы воспользовались двумя стратегиями: 1) удаление признака, содержащего большое количество пропусков (99%); 2) импутация данных в признаке, в котором количество пропусков не превышает порогового значения (5%), путем заполнения наиболее часто встречаемым значением (вывод о применимости моды был сделан исходя из гистограммы распределения).

Из представленных выше признаков также стоит отбросить признак "EYE" с высоким процентом пропусков (52%): удаление строк привело бы к серьезной потере размера датасета, а заполнение пропусков привело бы к возможному нарушению набора данных (неправильные данные). Также из описания датасета можно понять, что столбцы "FIRST APPEARANCE" и "YEAR" означают одно и то же. Кроме того, исследование количества пропусков дают одинаковые показатели, а значит, скорее всего, эти признаки содержат одинаковые данные. В дальнейшем можно оставить один из них. В остальных признаках можно либо выбросить строки с пустыми значениями, либо заполнить их.

Окончательное решение по выбору признаков, поступающих на вход модели, может приниматься после проведения корреляционного анализа. Также после проведения кросс-валидации и подбора оптимальных параметров модели возможен пересмотр набора признаков: либо их удаление, либо их добавление в зависимости от результатов работы алгоритма машинного обучения.